# Ingénierie IA

Kindi BALDE

Améliorez le produit IA de votre startup

#### Présentation des données

Problématique métier

**Avis Restau** est une société qui gère une plateforme permettant de mettre en relation des clients et des restaurants.

Elle souhaite améliorer sa plateforme de collaboration avec une nouvelle fonctionnalité IA.

Par exemple, si les utilisateurs postent des avis et des photos sur leur restaurant préféré, Avis Restau de son côté pourra utiliser ces informations pour :

- détecter les sujets d'insatisfaction présents dans les commentaires;
- labelliser automatiquement les photos (identifier les photos relatives à la nourriture, au décor dans le restaurant ou à l'extérieur du restaurant)



### Mission

Notre mission est de faire des études préliminaire d'une fonctionnalité de "détection des sujets d'insatisfaction" et de "labellisation automatique des photos postées".

# sommaire

- 1. Utilisation de l'API Yelp
- 2. Traitement de texte
- 3. Latent Dirichlet Allocation LDA
- 4. Traitement d'image
- 5. Extraction de feature
- 6. Réduction de dimensions des images
- 7. Visualisation des images
- 8. Démo avec Gradio



### Note

Nous allons travailler sur le traitement d'image et de texte. L'implémentation des algorithmes d'analyse de sentiment et d'annotation d'images n'est pas nécessaire.

# 1. Utilisation de l'API Yelp





### Intro to GraphQL General

GraphQL is a query language for APIs. What does this mean for you? Unlike regular SOAP or REST APIs, Manage App

need, and get

As a query lan

recreate endp be cleaner and

GraphQL gives you the ultimate flexibility in being able to specify in your API requests specifically what data you \$ curl -X POST -H "Authorization: Bearer ACCESS\_TOKEN" -H "Content-Type: o

> business(id: "garaje-san-francisco") { name

idalias

ratina

Email / Notifications

Display Requirements

"data": { "business": { "name": "Garaje", "id": "tnhfDv5Il8EaGSXZGiuQGg", "alias": "garaje-san-francisco", "rating": 4.5, "url": "https://yelp.com/biz/garaje-san-francisco"

Utilisation du GraphQL pour test

Utilisation de la library python requests

### 2. Traitement de texte

### Techniques pré traitement de texte

- 1. Tokenization ou le fait de découper les phrases ou paragraphes d'un texte en liste de mots.
- 2. Stemming ou le fait de prendre une liste "tokenizé" et d'enlever le suffixe des mots qui en ont.
- 3. Lemmatization comme le stemming mais va plus loin en ramenant chaque mot à sa racine.
- 4. Bag of word, une représentation des mots d'un corpus (un ensemble de mots du vocabulaire) en vecteur à indicatrice 1 pour le mot associé et 0 dans les autres cas.
- 5. Embedding, une représentation vectorielle des mots dans une matrice dimension plus petite où chaque mot est représenté par un vecteur a une signification car il prend en compte sa relation avec les autres mots du corpus (Word2Vect, Glove)

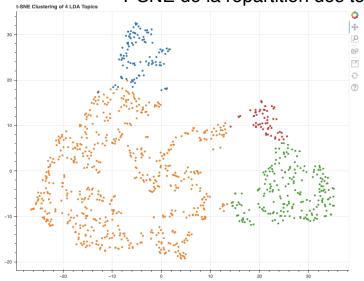
## 3. LDA

```
Topic 0
                             Topic 1
                               table
                     order
                                 service
     coffee
                      time
                     wait bar
       definitely
                                bad
 sauce
         fine
    beer
          taste
                      food
    meal
      Topic 2
                             Topic 3
  call
                          close
                           year
                    show
   customer
                                    month
                    feel
                                    open
work service
                          nail
                            help
            never
                                     car
             time
     hour
```

LDA pour faire une illustration de notre traitement de texte avec la librairie GenSim.

- Utilisation du corpus des mauvais commentaires
- Création des Topics et graphe WordCloud

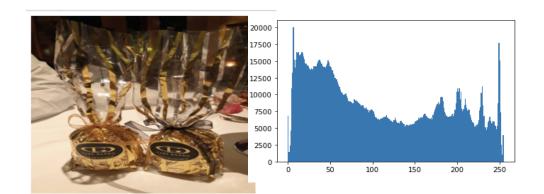
T-SNE de la répartition des topics

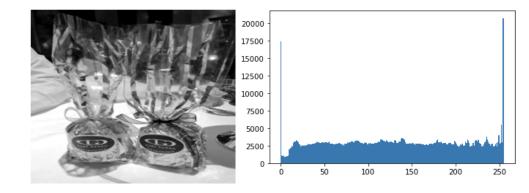


# 4. Traitement d'image

Plusieurs techniques de transformation de l'image :

- Normalisation ou chaque pixel représente une densité de probabilité
- auto contrast ou étirement de l'image pour réduire l'écart entre les zones sombres et celles brillantes sous l'effet de la lumière.
- Égalisation de l'histogramme ou le fait de répartir les pixels sur toute l'image.
- filtrage du bruit, ou le fait de réduire les grains dans une image sous

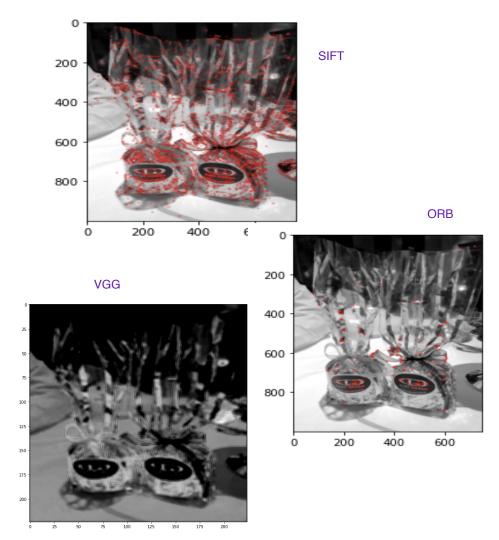




### 5. Extraction des features

Plusieurs techniques d'extraction des features sur une image :

- SIFT et ORB sont parmi beaucoup d'autres, des outils qui permettent d'extraire des informations pertinentes sur une image.
- VGG16 ou l'utilisation d'un modèle pré entrainé pour faire de l'extraction des features. Nous avons utilisé la première couche du modèle.

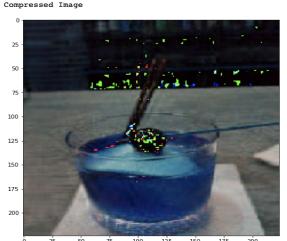


# 6. Réduction de dimensions des images

### Réduction de dimension

l'implémentation de l'ACP, nous a permet de trouver de nouvelles features, des pixels, qui résument de beaucoup les informations pertinentes se trouvant sur les images.

Nous obtenons une compression des images.





# 7. Visualisation des images

### Visualisation des données visuelles

L'utilisation du projecteur non linéaire, le T-SNE, nous a permet de projeter nos images sur un espace à deux dimensions.

Vu que nous avons travaillé sur un échantillon très petit (384 images), les classes ne sont pas significativement homogènes.

